




FMU · TÉCNICAS DE MACHINE LEARNING · N1

Sistema de Detecção de Fraudes em Transações Financeiras

Machine Learning supervisionado aplicado à classificação e prevenção de fraudes em dados financeiros simulados.

Disciplina: Técnicas de Machine Learning · **Instituição:** FMU · **Professor:** [Nome do Professor] · **Integrantes:** [Nomes dos Alunos]

CONTEXTO

O Problema: Fraudes no Ecosistema Digital

Com a digitalização acelerada dos serviços financeiros, o volume de transações online cresceu exponencialmente — e com ele, a sofisticação dos ataques fraudulentos. O desafio é identificar padrões suspeitos em tempo real com precisão e escala.

\$323B

Perdas Globais

Prejuízo estimado por fraudes cibernéticas em 2022 (Juniper Research)

3x

Crescimento

Aumento nas tentativas de fraude digital nos últimos 5 anos

1.7%

Taxa de Fraude

Proporção de transações fraudulentas no dataset utilizado

~10K

Transações

Volume total de dados históricos simulados no projeto

Made with GAMMA

Objetivo do Projeto

Desenvolver um sistema inteligente de classificação binária capaz de identificar transações fraudulentas com máxima sensibilidade, minimizando perdas financeiras e falsos negativos.



A prioridade central é **maximizar o Recall**: garantir que o maior número possível de fraudes reais seja detectado, mesmo que isso implique um leve aumento em falsos positivos — estratégia conservadora e adequada ao contexto financeiro.


Dataset e Distribuição das Classes

Features Utilizadas

- **valor** — montante da transação
- **hora_dia** — timestamp da operação
- **distancia_km** — distância geográfica
- **tentativas_senha** — tentativas de autenticação
- **novo_dispositivo** — flag de dispositivo desconhecido
- **saldo_anterior** — saldo antes da transação
- **tipo_cartao** — categoria do cartão utilizado

Distribuição das Classes


Classe



O dataset apresenta forte **desbalanceamento de classes**: apenas 1,7% das transações são fraudulentas. Este cenário exige técnicas específicas de balanceamento e métricas de avaliação além da acurácia simples.

Pipeline de Pré-processamento

Um pipeline robusto de pré-processamento é fundamental para garantir qualidade dos dados, evitar vazamento de informação (*data leakage*) e assegurar que o modelo aprenda padrões reais — não artefatos do processamento.



A divisão estratificada preserva a proporção de classes em treino e teste. O SMOTE é aplicado **exclusivamente no conjunto de treino**, prevenindo data leakage e garantindo avaliação realista do desempenho do modelo.

Balanceamento de Classes com SMOTE


O Problema do Desbalanceamento

Com 98,3% das transações sendo legítimas, um modelo ingênuo que sempre prediz "não fraude" alcançaria **98,3% de acurácia** — mas detectaria **zero fraudes**. A acurácia é enganosa neste contexto.

Como o SMOTE Funciona

O **SMOTE** (*Synthetic Minority Over-sampling Technique*) gera amostras sintéticas da classe minoritária por interpolação entre vizinhos próximos no espaço de features, equilibrando as classes sem simples duplicação de dados.

Antes vs. Depois do SMOTE



Após o balanceamento, o modelo recebe representação equitativa de ambas as classes durante o treinamento, aprendendo padrões discriminativos com muito mais eficácia.

Modelos de Machine Learning

Dois algoritmos foram avaliados: **Random Forest** como modelo principal e **Regressão Logística** como baseline de referência. A comparação permite quantificar o ganho real proporcionado pelo ensemble.

Critério	Random Forest	Regressão Logística
Tipo de Modelo	Ensemble de árvores de decisão	Modelo linear paramétrico
Robustez	Alta — resistente a outliers	Média — sensível a ruídos
Overfitting	Baixo controle via parâmetros	Risco em dados desbalanceados
Interpretabilidade	Feature Importance nativa	Coefficientes interpretáveis
Desempenho Esperado	Alto (modelo principal)	Baseline de referência

Random Forest foi selecionado como modelo principal por sua robustez natural a dados desbalanceados, capacidade de capturar relações não-lineares complexas e geração nativa de Feature Importance para análise explicativa.

Validação Cruzada Estratificada (Stratified K-Fold)

Por que Stratified K-Fold?

Em datasets desbalanceados, uma divisão aleatória simples pode resultar em folds sem representação da classe minoritária. O **Stratified K-Fold** preserva a proporção de classes em cada fold, garantindo avaliação confiável e estável.

Parâmetros Utilizados

- **k = 5 folds** — equilíbrio entre viés e variância
- **Estratificação** — proporção de 1,7% mantida em cada fold
- **Shuffle = True** — aleatorização antes da divisão
- **Random State fixo** — reprodutibilidade total dos experimentos

Estrutura dos Folds



Métricas de Avaliação — Recall como Prioridade

Em detecção de fraudes, **maximizar o Recall** é a prioridade absoluta: cada fraude não detectada representa perda financeira real. As métricas complementares garantem visão multidimensional do desempenho.

Accuracy

Proporção total de previsões corretas. Limitada em classes desbalanceadas — pode ser enganosa sozinha.

Precision

Dentre as previstas como fraude, quantas eram realmente fraude? Mede a confiabilidade dos alertas.

Recall ★

Dentre as fraudes reais, quantas foram detectadas? **Métrica principal do projeto.**

F1-Score

Média harmônica entre Precision e Recall. Equilíbrio entre detecção e confiabilidade dos alertas.

ROC-AUC


Capacidade discriminativa do modelo. Valores próximos de 1.0 indicam excelente separação entre classes.

Resultados Finais — Random Forest vs. Logistic Regression

Comparativo de Desempenho

Random Forest

Logistic Regression



Destaque: Random Forest

O **Random Forest** superou consistentemente a Regressão Logística em todas as métricas. O ganho mais expressivo foi no **Recall (+23 p.p.)** — detectando significativamente mais fraudes reais.

- **Accuracy:** 98,5%
- **Precision:** 0,85
- **Recall:** 0,88 ← **métrica principal**
- **F1-Score:** 0,86
- **ROC-AUC:** 0,98

- ✓ O modelo demonstrou excelente capacidade discriminativa (ROC-AUC 0,98) e alta sensibilidade na detecção de fraudes (Recall 0,88), validando a abordagem de ensemble com SMOTE e validação estratificada.